

TP ANÁLISIS DE LENGUAJES – PIPELINE

Alumno: Bautista Limer

1) Preparación de los datos (Pipeline)

Para analizar el archivo *CorpusLenguajes.txt*, armamos una canalización (pipeline) siguiendo los pasos vistos en la teoría. Primero tomamos el texto crudo y lo limpiamos: quitamos las “StopWords” (palabras vacías como is, the, and...) y limpiamos signos de puntuación y basura (- “). Después, usamos la sistematización con etiquetas POS para llevar las palabras a su forma base real (por ejemplo, los verbos quedan en infinitivo). Con ese corpus limpio, calculamos la matriz TF-IDF.

2) Las palabras mas y menos usadas:

Contando la apalabras del texto preparado, sacamos la jerarquía del Top 6 de las más usadas en todo el corpus:

Palabras	Veces que aparece
Python	7
Javascript	7
CPlus	5
Rust	5
Interpret	3
Language	3

En el otro extremo, la palabra menos utilizada no es una sola, sino un grupo de palabras que aparecen 1 sola vez porque son súper específicas (por ejemplo: browser, statically, beginner, nature).

3) Repeticiones en la misma oración:

Nos fijamos si había palabras que se repitieran dentro de una misma linea para ver donde se hacia énfasis. Encontramos que:

- En la **oración 1** se repite dos veces “Language” (al comparar lenguajes de alto y bajo nivel).
- En la **oración 8**, se repiten dos veces “require” y “compilation” para remarcar como funcionan Cplus y Rust en comparacion con JavaScript.

4) Análisis de la Matriz TF-IDF

Mirando los números que nos devolvió la tabla TF-IDF, pudimos comprobar lo que dice el apunte sobre esta técnica. Aunque “python” es la palabra que mas se nombra en todo el archivo, el algoritmo le da un “peso” muy bajo en la matriz (valores cercanos a 0,17). En cambio, palabras que casi no aparecen pero que son claves para entender una oración en particular (como “language” en la oración 1, que saca 0,64 de peso) reciben los puntajes mas altos. Osea el TF-IDF penaliza a las palabras que están en todos lados porque no te ayudan a diferenciar una oración de otra.

5) Gráfico de Distribución de Frecuencias

